El **AutoML (Automated Machine Learning)** automatiza el flujo de trabajo del aprendizaje automático: desde el preprocesamiento de datos y la selección de variables hasta el entrenamiento simultáneo de múltiples algoritmos y el ajuste de hiperparámetros. El siguiente análisis se restringe de forma exclusiva a los datos extraídos de tres artículos científicos y técnicos verificables sobre **PyCaret**, **H2O AutoML** y **AutoGluon**.

Caso 1: Predicción de diabetes tipo 2 según fenotipo y género (PyCaret)

- **Problema:** Detectar de forma temprana la diabetes mellitus tipo 2 (T2DM) analizando cómo interactúan el género y los datos fenotípicos (hábitos y características clínicas sin depender de pruebas genéticas complejas) para diseñar estrategias de prevención personalizadas en hombres y mujeres.
- **Qué se hizo:** Se analizaron los conjuntos de datos *Nurses' Health Study* y *Health Professionals' Follow-Up Study* utilizando 15 variables (como índice de masa corporal, antecedentes familiares de diabetes, hipertensión, colesterol, consumo de alcohol, carga glucémica, tabaquismo y actividad física), dividiendo los datos en tres subconjuntos: solo hombres, solo mujeres y total combinado. Se utilizó **PyCaret** (un framework de bajo código en Python) para preprocesar los datos y ejecutar simultáneamente **16 modelos distintos de clasificación**. Posteriormente, se evaluaron curvas de aprendizaje y se interpretó el impacto de cada variable mediante gráficos de importancia y valores SHAP utilizando el comando `interpret_model` (comprobable en la documentación oficial de PyCaret, módulo `pycaret.classification`: funciones `setup`, `compare_models` e `interpret_model`).
- **Resultado reportado:** El estudio evaluó los 16 algoritmos usando métricas de exactitud (*accuracy*), área bajo la curva (AUC), *recall*, precisión, F1-score, coeficiente Kappa, coeficiente de correlación de Matthews (MCC) y tiempo de entrenamiento (TT). En el subconjunto de datos de hombres, el modelo *Ridge Classifier* obtuvo una exactitud de **0.7013**, precisión de **0.7024**, *recall* de **0.7013**, F1-score de **0.6991**, Kappa de **0.3956**, MCC de **0.3989** y un tiempo de análisis de **0.0360 segundos**. El análisis con curvas de aprendizaje para el clasificador de Regresión Logística mostró convergencia entre las puntuaciones de validación y validación cruzada (indicando ausencia de sobreajuste), y el análisis SHAP confirmó que el género es un factor fenotípico significativo, aunque los autores concluyeron que las variables fenotípicas por sí solas tienen un poder predictivo moderado.
- **URL:** https://pmc.ncbi.nlm.nih.gov/articles/PMC11355927/ (también disponible en https://doi.org/10.3390/jpm14080804)
- **Referencia APA 7:** Gul, S., Ayturan, K., & Hardalaç, F. (2024). PyCaret for predicting type 2 diabetes: A phenotype- and gender-based approach with the “Nurses’ Health Study” and the “Health Professionals’ Follow-Up Study” datasets. *Journal of Personalized Medicine*, *14*(8), 804. https://doi.org/10.3390/jpm14080804

Caso 2: Predicción de parto prematuro con registros médicos electrónicos (H2O AutoML y AutoGluon)

- **Problema:** Predecir el riesgo de parto prematuro (*preterm birth*) a partir de datos administrativos y registros médicos electrónicos de alta hospitalaria para mejorar el cuidado prenatal sin depender de ingeniería de características manual (*ad-hoc feature engineering*).
- **Qué se hizo:** Se recopilaron registros médicos electrónicos de **715,962 participantes** con código de diagnóstico principal de parto, utilizando una muestra de entrenamiento de **536,971 casos**. Los investigadores entrenaron y compararon tres frameworks de AutoML: **H2O AutoML** (v3.40.0.2), **AutoGluon** y **Auto-sklearn**. Con estas herramientas se construyeron modelos basados en árboles, modelos ensamblados (*stacked ensembles*, que combinan las predicciones de varios algoritmos para reducir el error) y redes neuronales profundas. La importancia de las variables se calculó mediante permutación (*permutation-shuffling*). El funcionamiento del entrenamiento distribuido, la generación de *Stacked Ensembles* y la métrica de ordenamiento por defecto (AUC para clasificación binaria) se pueden comprobar en la documentación oficial de H2O.ai (`docs.h2o.ai`, sección *H2O AutoML: Automatic machine learning*, clase `H2OAutoML` y función `h2o.explain()`).
- **Resultado reportado: H2O AutoML** alcanzó la mediana de AUC más alta con **0.846**, seguido por **AutoGluon** con una mediana de AUC de **0.840** y **Auto-sklearn** con **0.820**. En eficiencia computacional, H2O AutoML registró la mediana de tiempo de entrenamiento más baja (**0.14 minutos**), superando a AutoGluon (**0.16 minutos**) y a Auto-sklearn (**4.33 minutos**). Por tipo de algoritmo, *Gradient Boosting Machines* (GBM) / *XGBoost* y los modelos *Stacked Ensemble* empataron con la mejor mediana de AUC (**0.846**), seguidos por *Random Forest* (**0.842**). Las variables clínicas más importantes identificadas fueron la rotura prematura de membranas (PROM), incompetencia cervical, ocupación y preeclampsia.
- **URL:** https://pmc.ncbi.nlm.nih.gov/articles/PMC10867966/ (también disponible en https://doi.org/10.3389/fped.2024.1330420)
- **Referencia APA 7:** Kong, D., Tao, Y., Xiao, H., Xiong, H., Wei, W., & Cai, M. (2024). Predicting preterm birth using auto-ML frameworks: A large observational study using electronic inpatient discharge data. *Frontiers in Pediatrics*, *12*, 1330420. https://doi.org/10.3389/fped.2024.1330420

Caso 3: Automatización en datos tabulares a gran escala y competencias reales (AutoGluon-Tabular)

- **Problema:** Superar las limitaciones de los sistemas AutoML tradicionales que dependen de búsquedas de fuerza bruta para selección de algoritmos y optimización de hiperparámetros (CASH), los cuales consumen excesivos recursos computacionales, fallan por falta de memoria en conjuntos de datos grandes o sobreajustan los datos de validación.
- **Qué se hizo:** Investigadores de Amazon Web Services (AWS) diseñaron y evaluaron **AutoGluon-Tabular** sobre benchmarks de conjuntos de datos estructurados, competencias reales de ciencia de datos en Kaggle (incluyendo *Otto Group Product Classification Challenge*) y un conjunto de datos masivo de aerolíneas de **115 millones de filas** (en pruebas conjuntas con NVIDIA RAPIDS en GPU). En lugar de priorizar el ajuste de hiperparámetros, AutoGluon automatiza el reconocimiento de tipos de columnas (numéricas, categóricas y texto), entrena una cartera de modelos en orden predefinido (como *Random Forests*, *XGBoost*, *CatBoost*, *LightGBM* y redes neuronales *feedforward*) y

aplica **ensamblado apilado multicapa (*multi-layer stack ensembling*)** combinado con *repeated k-fold bagging*. Esta arquitectura y el uso de las funciones `TabularPredictor.fit()` y `predict()` se pueden comprobar en la documentación oficial de AutoGluon (`auto.gluon.ai`, sección *AutoGluon-Tabular*).

- **Resultado reportado:** En las dos competencias evaluadas de Kaggle, AutoGluon superó al **99% de los científicos de datos participantes** tras solo **4 horas de entrenamiento** directo sobre los datos crudos sin procesar. En la prueba complementaria documentada por NVIDIA y AWS sobre el conjunto de datos de aerolíneas de 115 millones de filas, la integración de AutoGluon con GPUs (RAPIDS) aceleró el entrenamiento **25 veces** respecto al uso de CPUs, alcanzando una exactitud (*accuracy*) del **81.92%**, lo que representó un **7% por encima de la línea base de XGBoost**.
- **URL:** https://arxiv.org/pdf/2003.06505 (datos complementarios del caso de 115 millones de filas en https://developer.nvidia.com/blog/advancing-the-state-of-the-art-in-automl-now-10x-faster-with-nvidia-gpus-and-rapids/)
- **Referencia APA 7:** Erickson, N., Mueller, J., Shirkov, A., Zhang, H., Larroy, P., Li, M., & Smola, A. (2020). *AutoGluon-Tabular: Robust and accurate AutoML for structured data*. arXiv. https://doi.org/10.48550/arXiv.2003.06505

Framework	Caso de aplicación	Muestra / Datos	Métrica principal reportada	Tiempo de ejecución reportado	Documentación técnica oficial para verificación
PyCaret	Predicción de diabetes tipo 2 (Gul et al., 2024)	15 variables fenotípicas (subconjuntos por sexo y total)	Exactitud: **0.7013**, F1: **0.6991** (modelo *Ridge* en hombres; otros modelos)	**0.0360 s** (*Ridge Classifier* en hombres)	Documentación de `pycaret.classification` (`setup`, `compare_models`, `interpret_model`)
H2O AutoML	Predicción de parto prematuro (Kong et al., 2024)	715,962 registros (536,971 de entrenamiento)	Mediana de AUC: **0.846** (superando a AutoGluon con **0.840** y Auto-sklearn con **0.820**)	Mediana de **0.14 min** (frente a 0.16 min de AutoGluon y 4.33 min de Auto-sklearn)	Documentación de H2O-3 (`docs.h2o.ai`, clase `H2OAutoML`, parámetro `max_runtime_secs` y `h2o.explain`)
AutoGluon	Competencias Kaggle y dataset de aerolíneas (Erickson et al., 2020)	2 competencias Kaggle / 115 millones de filas (aerolíneas)	Superó al **99%** de participantes en Kaggle / Exactitud de **81.92%** en aerolíneas	**4 horas** en Kaggle / Aceleración **25x** en GPU para aerolíneas	Documentación de AutoGluon (`auto.gluon.ai`, módulo `autogluon.tabular`, clase `TabularPredictor`)